

Approfondimento di Intelligenza Artificiale

Studente: Tristano Munini

ANNO ACCADEMICO 2019-2020

1 Introduzione

TODO

Esempio di citazione [5].

2 GAN

Uno tra i primi metodi che permettevano di generare immagini sintetiche faceva uso di una particolare versione di *Auto-Encoder* o *Variational Auto-Encoder*. Come nel caso degli AE classici, i VAE hanno una struttura che ricorda una clessidra: la prima metà della rete permette di comprimere l'input, mappandolo in quello che viene chiamato spazio latente, di minor dimensione rispetto allo spazio di partenza; la seconda metà, invece, prende l'input compresso e lo mappa nello spazio di partenza. Durante il training si vuole ottimizzare la compressione in modo che non ci sia perdita di informazione, questo viene effettuato andando a minimizzare la distanza tra input originale ed input ricostruito. Nei VAE, in corrispondenza del punto della rete in cui si raggiunge il livello massimo di compressione (*bottleneck*), invece di essere generato il vettore compresso z , viene prodotta una coppia di vettori σ e μ che descrivono una distribuzione di probabilità dei vettori compressi. In questo modo è possibile campionare z dalla distribuzione appena prima della decompressione. Il campionamento non è un'operazione differenziabile e questo rende inapplicabile l'algoritmo della *backpropagation*, quindi risulta necessario effettuare quello che viene chiamato *reparametrization trick*. Rappresentando z come $z = \mu + \sigma \odot \varepsilon$ in cui $\varepsilon \sim \mathcal{N}(0, 1)$, quindi ε è campionata da una distribuzione normale, è possibile effettuare l'operazione di *sampling* all'esterno della rete. In questo modo μ e σ possono essere utilizzati per il calcolo del gradiente e quindi usati durante la *backpropagation*.

Dopo questa breve panoramica sulle VAE, ispirata alla lezione del MIT [4], ci si accorge che sono una soluzione astuta ma complessa e che le loro prestazioni sono vincolate strettamente allo spazio latente che si è trovato durante il training.

Le *Generative Adversarial Network* (GAN) sono state modellate appositamente per trovare un'altra soluzione al problema della creazione di immagini sintetiche. Nelle GAN sono presenti due modelli che, citando [3], “*vengono addestrati simultaneamente da un processo contraddittorio. Un generatore (“l’artista”) impara a creare immagini che sembrano reali, mentre un discriminatore (“il critico d’arte”) impara a distinguere le immagini reali dai falsi*”. Riformulando la frase si può dire che una GAN, come si vede in Figura 1, è composta da due reti: la prima viene chiamata Generatore G ed il suo scopo è fornire in output un x_{fake} che sembri appartenere alla distribuzione del *dataset* reale fornito; la seconda, detta Discriminatore D , prende in input un x_{fake} ed un x_{real} estratto dal *dataset* e deve riuscire a distinguere il dato reale da quello sintetico. Quindi il training viene svolto in quattro momenti:

- all'inizio G a partire da del rumore randomizzo genera, basandosi sulle sue conoscenze attuali, un x_{fake} ;
- successivamente D stabilisce quale tra x_{fake} ed un x_{real} fornito è sintetico;
- la prestazione di D viene valutata con il *ground truth* e con questa può essere effettuata la *backpropagation* su D ;
- con l'output del discriminatore è possibile determinare anche la prestazione di G , infatti se questo è riuscito a confondere D significa che sta raggiungendo una buona conoscenza del dominio.

Notare come G sia in grado di mappare del rumore casuale nello spazio delle *feature* del dominio e che quindi, una volta allenato, possa essere sfruttato molto facilmente: basterà avere del rumore da cui partire. Rispetto ai VAE le GAN




Figura 1: Architettura di una generica GAN (dalle slide in [4])

risultano non solo più intuitive ma permettono anche di raggiungere prestazioni veramente sorprendenti, come si può vedere in [1], in cui anche gli esperti umani vengono ingannati dai prodotti della rete.

Va fatto notare però che le GAN sono notoriamente difficili da allenare, basti pensare che prima dell'allenamento entrambe le sotto-reti non hanno alcuna conoscenza del dominio e si chiede loro di guidarsi a vicenda. Se il discriminatore converge rapidamente è possibile che dia una valutazione così bassa al generatore da causare il *vanishing gradient problem*, rendendo quindi impossibile che G possa migliorarsi. Un altro problema noto è quello del *model collapse* che si verifica quando G riproduce molto bene soltanto una piccola frazione del dominio. In questo modo riesce ad ottenere punteggi molto alti ma a discapito della generalità.

leggere xke
GAN difficili

aggiungere robe dal paper originale se si deve allungare

3 RL

Il *Reinforcement Learning* (RL) assieme al *Supervised Learning* ed al *Unsupervised Learning* è il terzo paradigma di apprendimento autonomo. Gli ultimi due paradigmi sfruttano un dataset, rispettivamente con e senza label, per portare a termine un specifico task oppure generare nuova informazione. Nel caso del RL il dataset viene sostituito con un ambiente (*environment*) nel quale il modello può eseguire delle azioni e osservarne le conseguenze, quindi come l'ambiente viene modificato dall'azione. In questo paradigma il modello viene anche chiamato "agente" e l'elenco, discreto oppure continuo, delle azioni eseguibili prende il nome di *action space*. L'agente impara grazie ad un *reward*, positivo o negativo, associato al risultato delle sue azioni. Il suo obiettivo è quello di massimizzare la somma dei *reward* sul lungo termine, quindi si vuole che scopra e adotti una strategia (*policy*) efficace nell'ambiente considerato. Poiché è necessario svolgere numerose iterazioni del tipo *trial-and-error* e considerato che solitamente un fallimento corrisponde anche ad una grande acquisizione di informazione, bisogna creare degli *environment* virtuali che siano il più vicino possibile al dominio di applicazione finale e che permettano un'esecuzione rapida e senza costi aggiuntivi.

Riprendendo quanto illustrato in [6] ed in [7], una prima modellazione sfrutta una funzione che valuta la qualità dell'azione svolta

$$Q(s_t, a_t) = \mathbb{E}[R_t | s_t, a_t]$$

in cui s_t è lo stato corrente cioè come l'ambiente si presenta all'agente, a_t è l'azione che l'agente svolge all'istante t , mentre a destra dell'uguale si ha il valore atteso del *reward* totale R_t che l'agente potrà ricevere in futuro, quindi negli s_{t+i} con $i = 1, 2, \dots$, se esegue a_t in s_t . Calcolare R_t risulta critico perché la sua naturale definizione è

$$R_t = \sum_{i=t}^{\infty} \gamma^i r_i =$$

in cui $0 < \gamma < 1$ viene chiamato *discount factor* ed indica la *greediness* del modello. In questa casistica risulta utile approssimare $Q(s, a)$ con una rete neurale, in questo modo si evita di dover fissare a mano un *hyperparameter* come ad esempio il numero di somme da effettuare per approssimare R_t . L'idea è fornire alla rete, detta anche *Q-Network* [2], lo stato corrente ed ogni possibile azione lecita e successivamente scegliere l'azione a cui la rete assegna il valore più alto. Procedendo in questo per ogni stato che si incontra è possibile seguire una policy $\pi(s)$ ottimale ad ogni passo, quindi complessivamente si è trovata una strategia ottimale che porta al guadagno massimo sul lungo periodo.

qui mettere loss function e spiegarla

spiegare
meglio in
caso

L'approccio appena presentato richiede che l' *action space* sia discreto e di dimensione ridotta, altrimenti sarebbe impossibile iterare su tutte le azioni per selezionarne la migliore. Per ovviare a questo problema si possono utilizzare

modelli che provano ad ottimizzare direttamente la *policy* $\pi(s)$, questi modelli prendono il nome di *Policy Learning* e vengono allenati tramite il *Policy Gradient*. L'idea principale è approssimare π con una distribuzione di probabilità, in questo modo risulta naturale utilizzare un *action space* continuo, inoltre si può ottenere una strategia non deterministica, quindi più flessibile e con maggiori capacità esplorative durante il training. Dato uno stato s l'azione a verrà estratta secondo:

cite paper?

$$a = \pi(s) \sim P(a|s) \quad \text{in cui} \quad \int_{a=-\infty}^{\infty} P(a|s) = 1$$

poiché $P(a|s) = \mathcal{N}(\mu, \sigma^2)$

Riferimenti bibliografici

- [1] Karras et al. «A Style-Based Generator Architecture for Generative Adversarial Networks». In: (2019). URL: <https://arxiv.org/pdf/1812.04948.pdf>.
- [2] V. Mnih et al. *Playing Atari with Deep Reinforcement Learning*. URL: <https://www.cs.toronto.edu/~vmnih/docs/dqn.pdf>.
- [3] *Deep Convolutional Generative Adversarial Network*. URL: <https://www.tensorflow.org/tutorials/generative/dcgan>.
- [4] *Deep Generative Modeling — MIT 6.S191*. URL: <https://youtu.be/rZufA635dq4>.
- [5] T. Munini. «The Monster Hunting Era». In: *The Hunter Catalog* 5 (2020), pp. 9–19.
- [6] *Reinforcement Learning — MIT 6.S191*. URL: <https://youtu.be/nZfaHixDD5w>.
- [7] A. Violante. *Simple Reinforcement Learning: Q-learning*. URL: <https://towardsdatascience.com/simple-reinforcement-learning-q-learning-fcddc4b6fe56>.